

Latam-Eval-Framework

UC Autumn of Code 2026

El objetivo del proyecto **Latam-Eval-Framework** es implementar un framework de evaluación robusto y agnóstico (al modelo) para medir el desempeño de LatamGPT en tareas de procesamiento de lenguaje natural (NLP) con enfoque en lenguas indígenas (en nuestro caso, el guaraní). Se busca comparar el desempeño de LatamGPT frente a otros modelos fundacionales similares (ALIA, GPT, Gemini, Grok, Claude o Llama, Qwen, Gemma, entre otros) bajo un contexto lingüístico guaraní-hablante.

Este proyecto se enmarca dentro del proyecto GuaranIA, llevado a cabo por el CIDIT y el BID-Lab. Para más información, visitá este [link](#).

Requerimientos funcionales

1. **Definición de Evaluación:** La aplicación debe implementar una evaluación de tipo **Benchmark Comparativo** (*Zero-shot* y *Few-shot* [3 a 5]) contrastando LatamGPT contra modelos base fundacionales (**al menos 2 más**).
 - a. **Soporte Multimodelo:** La aplicación debe permitir la evaluación de múltiples modelos, al menos de forma secuencial, idealmente simultáneamente. Debe incluir integraciones mediante librerías como transformers para modelos locales o (para modelos en la nube, e.g., langchain con [openrouter.ai](#) o Azure AI Foundry) para unificar las llamadas a diferentes proveedores.
2. **Gestión de Dataset:** El sistema debe procesar un dataset de evaluación que consistirá en pares de instrucciones y respuestas en guaraní.
 - a. **Sistema de Configuración:** El usuario debe poder definir mediante un archivo config.yaml (.json o similar) qué modelos desea evaluar, los parámetros (temperature, top_p) y el dataset de entrada.
3. **Cálculo de Métricas:** La aplicación debe calcular automáticamente métricas de calidad: **ROUGE** (coherencia), **BLEU** (precisión) y **METEOR**

(alineación/recuperación), además de una métrica de **Pertinencia Cultural** mediante **métricas de similitud de embeddings** utilizando modelos entrenados en guaraní (e.g., `mmaguero/multilingual-bert-gn-base-cased` de Hugging Face), el cual permite comparar la proximidad semántica del contenido generado con un corpus de validación de normas y valores de la cultura guaraní.

- 4. **Generación de Reportes:** El sistema debe exportar los resultados de la evaluación en formato `JSON` y generar visualizaciones (e.g., gráficos de radar) sobre el desempeño por métrica lingüística de cada modelo evaluado sobre determinado dataset.

Requerimientos no funcionales

- Diseño modular para añadir nuevos modelos o datasets.
- Interfaz CLI clara para ejecutar las pruebas.
- Manejo robusto de errores, tanto de LLMs en local, como de conexión con APIs de LLMs.
- Seguridad en el manejo de token y API Keys (uso de variables de entorno).
- Documentación técnica (`README.md` detallado) y manejo de dependencias.

Habilidades a desarrollar

Integración de Large Language Models (LLMs), ingeniería de prompts, evaluación estadística de modelos de IA, y diseño de herramientas de diagnóstico lingüísticas.

Objetivos y Evaluación

#	Objetivo	Entregable	Puntos	Deadline
1	Arquitectura Multimodelo: Implementar una clase base abstracta y adaptadores para al	Repositorio con diseño de patrones (Adapter/Strategy) documentado con	10	23-03-2026

	menos 3 modelos (LatamGPT + 2 externos). docstrings y siguiendo PEP8. Al menos un modelo y un dataset añadido.		
2	CLI de Benchmarking: Desarrollar la interfaz que permita ejecutar algo como esto: <pre>eval-llm --models latam-gpt,gpt-4o --dataset my_guarani_set.json{1}.</pre>	Aplicación funcional documentada con docstrings y siguiendo PEP8. Se espera que se incorporen al menos dos modelos más y otro dataset. Se excluye de esta etapa: métrica de similitud de embeddings.	25 18-05-2026
3	Análisis Comparativo: Generar un reporte técnico que analice el Cost-Performance Ratio (desempeño vs latencia/costo [si aplica]) de los modelos.	Repositorio documentado con docstrings y siguiendo PEP8 y reporte final / visualizaciones comparativas. Se agrega la métrica faltante: métrica de similitud de embeddings.	15 8-06-2026

Definición de Evaluación

- La evaluación de cada entrega se realizará teniendo en cuenta, por un lado, los entregables mencionados y, por otro, el conocimiento del código y de la arquitectura de la solución, demostrado mediante una defensa oral con el/la/l@s evaluador/@s.
- Para obtener el total de puntos en cada entrega, el interesado debe cumplir con el 100% de los entregables mencionados arriba y ser capaz de explicar con seguridad cada aspecto de la solución y justificar con suficiencia las decisiones técnicas. En caso contrario, se le asignará, de acuerdo a criterios subjetivos de el/la/l@s evaluador/@s, una fracción de los puntos en juego considerando el manejo del lenguaje de programación (Python), herramientas de versionamiento (Git, Github), implementación de convenciones de estilo (PEP8), arquitectura de la solución y documentación.

Benchmark Guaraní-Paraguayo

Los dataset serán provistos durante el desarrollo de la **entrega 1**, a más tardar antes de la **entrega 2**. Para que la evaluación sea relevante en Paraguay y el guaraní que se habla, el dataset incluirá:

- **Code-switching:** Frases que mezclan español y guaraní (Jopará/Jehe'a) para ver qué modelo mantiene la coherencia.
- **Préstamos lingüísticos:** Palabras que se prestan de otros idiomas (como el español o el inglés), incluyendo préstamos adaptados al guaraní desde otros idiomas, e.g., *planéta* para planeta o *ekípo* para equipo.
- **Contexto Local:** Preguntas sobre legislación paraguaya, geografía o cultura que un modelo generalista podría errar pero uno regional (LatamGPT) debería acertar.

Uso de inteligencia artificial

Se permite el uso de copilotos de código pero debe ser notificado por escrito indicando que se utilizarán para la optimización de los algoritmos creados

previamente por el alumno o como una plantilla base o de lo contrario, indicar y justificar el uso. En todo caso, el interesado será el responsable último de la solución de código presentada, no delegando todo a la IA.

Contacto

Para cualquier duda sobre el trabajo contactar con marvin-aguero@hotmail.com.